

Modélisation du Web et algorithme PageRank

Rémi Parrot

15 mars 2026

Table des matières

1	Introduction	2
2	Modélisation du Web	2
2.1	Représentation du Web par un graphe orienté	2
2.2	Matrice d'adjacence	2
2.3	Matrice de transition	2
2.4	Limites du modèle	3

1 Introduction

Avec l'essor du Web, les moteurs de recherche sont devenus des outils incontournables pour naviguer dans une masse d'information qui ne cesse de croître. Le problème, c'est que le nombre de pages indexées est tel qu'il faut bien trouver un moyen de les ordonner. Pas seulement par pertinence thématique, mais aussi par importance relative. C'est précisément ce que propose l'algorithme *PageRank*, développé par Sergey Brin et Larry Page à la fin des années 1990 pour le moteur de recherche Google.

Le principe de base est assez intuitif : une page Web est d'autant plus importante qu'elle est citée par d'autres pages, et surtout par des pages elles-mêmes bien référencées. Cette logique circulaire conduit naturellement à modéliser le Web comme un graphe orienté, où chaque page correspond à un sommet et chaque lien hypertexte à une arête orientée.

À partir de ce modèle, on peut voir la navigation d'un utilisateur comme celle d'un *surfeur aléatoire* qui se déplace de page en page en cliquant sur des liens au hasard. Son comportement suit alors une dynamique probabiliste que l'on formalise à l'aide d'une chaîne de Markov. Le classement des pages revient alors à trouver la distribution stationnaire de cette chaîne, c'est-à-dire la fréquence limite avec laquelle chaque page est visitée.

Ce projet a pour but de détailler cette modélisation et l'algorithme qui en découle. On commencera par construire le modèle de graphe orienté et la matrice de transition associée au surfeur aléatoire. On introduira ensuite la matrice de Google, qui corrige certaines limitations du modèle de base — notamment les puits et les composantes déconnectées — et garantit l'existence d'une distribution stationnaire unique. Pour finir, on implémentera le calcul du PageRank en Python et on observera son comportement sur des graphes générés aléatoirement.

2 Modélisation du Web

2.1 Représentation du Web par un graphe orienté

On modélise l'ensemble des pages du Web par un graphe orienté $G = (V, E)$.

- Chaque sommet représente une page web.
- Chaque arête orientée représente un lien hypertexte.

Si une page j contient un lien vers une page i , on note $j \rightarrow i$.

Cette modélisation permet d'utiliser des outils d'algèbre linéaire et de théorie des graphes pour étudier la structure du Web.

2.2 Matrice d'adjacence

Soit n le nombre de pages.

On définit la matrice d'adjacence $A \in \{0, 1\}^{n \times n}$ par :

$$a_{ij} = \begin{cases} 1 & \text{si la page } j \text{ pointe vers la page } i, \\ 0 & \text{sinon.} \end{cases}$$

Ainsi, la colonne j de la matrice A représente l'ensemble des liens sortants de la page j .

2.3 Matrice de transition

On suppose maintenant qu'un internaute parcourt le Web de manière aléatoire : à chaque étape, il choisit uniformément un des liens sortants de la page courante.

On définit alors la matrice de transition P par :

$$P_{ij} = \begin{cases} \frac{1}{\deg(j)} & \text{si } j \rightarrow i, \\ 0 & \text{sinon,} \end{cases}$$

où $\deg(j)$ désigne le degré sortant de la page j , c'est-à-dire :

$$\deg(j) = \sum_{i=1}^n a_{ij}.$$

La matrice P vérifie la propriété suivante :

$$\sum_{i=1}^n P_{ij} = 1$$

pour toute colonne j telle que $\deg(j) \neq 0$.

Ainsi, P est une matrice stochastique par colonnes.

2.4 Limites du modèle

Ce modèle présente cependant deux difficultés principales :

- Certaines pages peuvent ne posséder aucun lien sortant.
- Le graphe peut être composé de plusieurs composantes non connectées, empêchant l'existence d'une distribution stationnaire unique.

Ces problèmes seront résolus dans la section suivante grâce à l'introduction de la matrice de Google.